

ESField: 基于物理机会位点势能场的推断期引导口袋分子生成

Anonymous Authors¹✉

¹Internal manuscript draft for method development

结构基础药物设计中的口袋条件三维分子生成已经能够直接生成与蛋白口袋形状相匹配的候选配体,但现有模型通常主要学习数据中的几何共现模式,对高能水释放、稳定水保留和疏水空腔填充等局部物理机会利用不足。本文提出 ESField,一种推断期可插拔的能量位点引导框架。ESField 首先离线检测蛋白口袋中的物理机会位点,构建包含位点类型、中心坐标和有效半径的静态位点地图;随后训练一个势能网络,学习不同原子类型在不同位点附近的适配性势能;最后在扩散模型或流匹配模型采样过程中,将势能网络关于原子坐标的梯度注入去噪分数或速度场。该框架不改变预训练生成模型的主体参数,不要求在每个采样步重新运行昂贵的物理模拟,并且能够将“正确类型原子移动到正确物理位点”这一药化直觉转化为可微的推断期引导信号。本文给出问题定义、数据构建、势能学习目标、采样引导公式与后续实验设计,不报告任何尚未完成的实验结果。

structure-based drug design | 3D molecule generation | energy guidance
| hydration sites | pocket hotspots

Correspondence: Internal draft, no correspondence address.

Introduction

面向蛋白口袋的三维分子生成正在成为结构基础药物设计 (structure-based drug design, SBDD) 中的核心生成范式。与传统虚拟筛选先枚举后打分不同,口袋条件生成模型试图直接从蛋白结合腔出发,生成形状互补、相互作用合理且具备药物样性质的候选小分子。扩散模型、流匹配模型以及偏好对齐方法已经在该方向上快速发展,能够在 CrossDocked2020 等数据集上生成较高 Vina 亲和力的候选分子,并逐渐开始关注蛋白构象变化、合成可及性和多目标优化等问题 (1-5)。

然而,当前模型仍然存在一个关键缺口:它们通常把口袋看作由蛋白原子诱导出的几何和化学环境,而没有显式建模口袋中可被利用的局部物理机会。例如,高能水分子的置换可能显著提高配体结合自由能收益,稳定水的错误置换可能破坏有利水网络,疏水空腔的充分填充常常影响配体形状互补与疏水收益。已有研究反复表明,水分子和口袋环境会显著影响结合亲和力预测与药物设计决策 (6-8);同时,HydraProt、SuperWater、WATsite、SILCS-Hotspots 等工作也说明,口袋中水位置、热点和可药性区域可以被独立预测或分析 (9-12)。这些信号在传统药化分析中很有价值,但尚未被系统地转化为三维分子生成过程中的可微引导力。

本文的核心观点是:口袋中的物理机会不一定要完全内化到生成模型训练中,也可以作为推断期的外部能量场注入。能量引导扩散已经有理论和方法基础,例如 CEP 证明并学习了一类能量函数定义下的精确中间引导 (13)。PIDiff 等工作进一步说明,在分子生成中引入物理先验能够改善结构合理性和结合相关指标,但其物

理约束主要在训练时进入损失函数 (2)。与之不同,本文关注一种更轻量、更可插拔的设置:对任意给定蛋白口袋,先离线构建物理机会位点地图,再在采样阶段用学习到的势能网络对生成轨迹施加梯度修正。

我们提出 ESField (Energy-Site Field)。ESField 的流程包括三步。第一,使用成熟工具离线识别口袋中的高能水、稳定水和疏水空腔,形成静态位点地图。第二,从真实蛋白-配体复合物中抽取“原子-位点”配对,并构造类型打乱和错误构象等负样本,训练一个势能网络为每个原子类型和位点类型组合输出标量势能。第三,在扩散或流匹配采样中,根据当前原子坐标和类型分布计算总势能,并将其梯度加入模型的分数或速度场。这样,疏水碳可以被拉向疏水空腔,氢键供体或受体可以被拉向适合置换的高能水位点,而不兼容原子则会被稳定水或错误位点排斥。

本文的预期贡献如下:

- 提出一种将离线物理机会位点转化为推断期可微势能场的 SBDD 生成框架,使高能水、稳定水和疏水空腔能够直接影响三维分子生成轨迹。
- 设计一个原子-位点势能网络,通过真实复合物正样本和构造负样本学习不同原子类型与不同位点类型之间的吸引或排斥关系。
- 给出适配扩散模型和流匹配模型的统一梯度引导公式,使该方法能够作为预训练生成模型的 plug-in guidance,而不是重新训练整个生成器。
- 明确后续实验协议,包括主实验、消融、位点命中分析、亲和力评估和失败案例分析,避免在实验尚未完成时伪造结果。

Related Work

Pocket-conditioned 3D molecule generation. 口袋条件分子生成的目标是在给定蛋白结合位点的条件下,生成三维坐标、原子类型和化学键均合理的配体。近年来,扩散模型和流匹配模型成为该方向的主流技术路线。PIDiff 将结合自由能相关的物理先验纳入模型训练,使生成过程不仅依赖几何信息,也受到物理化学原则约束 (2)。DynamicFlow 进一步将蛋白动态态纳入 SBDD,通过全原子流模型生成 holo-like 口袋和对应配体 (3)。DecompDPO 和 SYNC 则分别从偏好优化、分解式目标和合成可及性角度改进生成模型,使 SBDD 更接近实际药物发现流程 (4, 5)。

这些方法说明,SBDD 的下一阶段不只是提升几何拟合度,而是把可解释的药物设计目标注入生成过程。ESField 与这条方向一致,但关注点不同:我们不把物理

信息作为全局训练损失，也不要求重新训练主生成模型，而是把口袋级物理机会抽象为静态位点地图，并在采样时作为外部能量项注入。

Water, hotspots, and physical opportunities in binding pockets. 水分子在蛋白-配体结合中具有多重角色。某些高能水被配体置换后可带来有利自由能贡献；某些稳定水则可能作为结构或相互作用网络的一部分，错误置换会损害结合。近期结合亲和力预测和水位置预测工作均显示，显式考虑水分子能够改善对蛋白-配体相互作用的理解 (6, 7, 10, 11)。WATsite 通过显式水分子分子动力学轨迹估计 hydration site 的热力学性质，可用于识别高能水和稳定水 (9)。

除水之外，口袋热点和疏水空腔同样是重要的设计机会。fpocket 基于 Voronoi tessellation 与 alpha sphere 检测蛋白表面的口袋和空腔 (14)。SILCS-Hotspots、动态热点分析和 cryptic pocket 预测也说明，从蛋白结构或模拟中提取热点，再用机器学习排序或解释其可药性，是一个成熟且有效的思路 (12, 15, 16)。ESField 借鉴这类位点检测思想，但不把任务定义为“识别位点”。位点识别在预处理阶段完成；模型学习的是“某类原子应如何响应某类位点”。

Energy-guided generation. 能量引导采样为在生成模型中注入外部目标提供了自然接口。若目标分布可写为基础生成分布与能量项的乘积，则能量关于样本坐标的梯度可以作为推断期修正项。CEP 从理论上讨论了能量函数定义下扩散采样的中间引导，并给出学习精确引导的对比能量预测目标 (13)。Energy-based flow matching 等工作也从能量视角重新理解结构生成和流模型 (17)。与通用能量引导不同，ESField 的能量项不是全分子黑箱打分，而是分解在原子-位点对上的局部势能。这种设计有三个优点。第一，梯度方向具有可解释性：每个原子受到哪些位点吸引或排斥可以直接追踪。第二，能量计算只依赖预先保存的位点地图和当前生成状态，不需要在采样时运行 docking 或 MD。第三，局部势能天然适配逐原子三维坐标更新，可以同时服务于扩散模型的 score correction 和流匹配模型的 velocity correction。

Method

Problem definition. 给定一个蛋白口袋 P ，目标是生成一个配体三维结构 $M = (X, A, B)$ ，其中 $X = \{\mathbf{x}_i\}_{i=1}^N$ 为原子坐标， $A = \{a_i\}_{i=1}^N$ 为原子类型， B 为化学键。假设已有一个预训练口袋条件生成模型 G_θ 。在扩散模型中， G_θ 提供每个时间步的分数估计 $\mathbf{s}_\theta(\mathbf{z}_t, t, P)$ ；在流匹配模型中， G_θ 提供速度场 $\mathbf{v}_\theta(\mathbf{z}_t, t, P)$ 。本文不改变 G_θ 的训练方式，而是在推断期引入一个由口袋物理机会位点定义的势能项 $\mathcal{E}_\phi$ ，使采样轨迹偏向更低势能的原子-位点构型。

对每个蛋白口袋，我们预处理得到静态位点地图：

$$S(P) = \{s_j = (\mathbf{c}_j, r_j, \tau_j, \mathbf{u}_j)\}_{j=1}^K, \quad (1)$$

其中 $\mathbf{c}_j$ 是位点中心， r_j 是有效半径， τ_j 是位点类型， $\mathbf{u}_j$ 是可选的位点属性，例如 hydration free energy, occupancy、疏水性分数或工具置信度。当前阶段考虑三类位点：高能水、稳定水和疏水空腔。更复杂的金属配位、侧链诱

导口袋或明确水桥网络暂不纳入主方法，以保持第一版实验闭环清晰。

Overview of ESField. ESField 的总体流程如 Fig. 1 所示。一个关键边界是：势能网络不是位点检测器。位点检测由 WATsite、fpocket 或后续可替换工具离线完成，生成过程只读取静态位点地图。因此，对于同一蛋白口袋，位点地图可以复用到多轮分子生成中；预处理开销不会随采样次数线性增长。

Physical opportunity site map. 我们把位点定义为口袋中可被药物设计利用或需要避免破坏的局部区域。当前版本包括三类。

High-energy water sites. 高能水位点表示在口袋中热力学不稳定、被适当配体原子置换后可能带来自由能收益的水位置。对于这类位点，势能网络应学习哪些原子类型能够合理占据或替代该水位点。例如，氢键供体或受体可能与附近蛋白极性环境形成互补相互作用，疏水原子也可能在特定上下文中通过置换不利水获得收益。具体兼容关系不手工固定，而由真实复合物中的原子-位点配对学习。

Stable water sites. 稳定水位点表示可能参与水桥或稳定氢键网络的水位置。第一版方法将其主要视为需要避免错误占据的区域：若生成原子类型与稳定水位点不兼容，势能应升高并产生排斥梯度。后续可以扩展到显式水桥设计，即允许某些配体原子在稳定水附近形成水介导相互作用，而不是简单远离。

Hydrophobic cavities. 疏水空腔表示未充分填充的非极性区域。对于疏水碳、卤素或芳香原子，势能网络应倾向于输出低势能；对于强极性原子或电荷原子，则倾向输出高势能。该类位点可由 fpocket 等工具从口袋几何与 alpha sphere 特征中提取。

每个位点保存为 $(\mathbf{c}_j, r_j, \tau_j, \mathbf{u}_j)$ 。其中 $\mathbf{u}_j$ 的最小实现可以只包含一个工具置信度；更完整实现可包含 hydration free energy、enthalpy、entropy、occupancy、疏水性分数和局部蛋白原子组成。这种设计允许第一版使用简单特征闭环，后续再用更强的位点描述符增强性能。

Training pair construction. 训练数据来自已解析或已对齐的蛋白-配体复合物。对每个复合物，先构建口袋位点地图 $S(P)$ ，再遍历配体原子 i 。若某个位点 s_j 满足距离阈值

$$\|\mathbf{x}_i - \mathbf{c}_j\|_2 \leq \alpha r_j + \beta, \quad (2)$$

则构建候选原子-位点配对 $z_{ij} = (\mathbf{x}_i, a_i, s_j)$ 。这里 α 和 β 是可调容忍参数，用于处理不同位点半径和晶体结构噪声。若一个原子命中多个位点，可保留最近位点，也可按距离核保留多个软配对。

正样本来自真实复合物中空间上成立的原子-位点配对。直觉上，真实配体原子出现在某个位点附近，说明这种原子类型与该口袋环境至少不是明显不合理。负样本由三类方式构造：

- **Type-swapped negatives:** 固定原子坐标和位点，将原子类型替换为不兼容或随机类型，形成错误类型-位点组合。
- **Decoy-pose negatives:** 从错误 docking pose 或扰动构象中提取距离位点很近但整体相互作用差的配对。

Stage 1: Offline site map construction. For each protein pocket, run WATsite/fpocket-like tools to extract high-energy water sites, stable water sites, and hydrophobic cavities. Save centers, radii, types, and confidence features.

Stage 2: Energy network learning. From protein-ligand complexes, pair ligand atoms with nearby sites. Treat observed compatible atom-site pairs as positives and type-swapped or decoy-derived pairs as negatives. Train a scalar potential network $E_\phi(\mathbf{x}, a, s)$.

Stage 3: Inference-time guidance. During diffusion or flow sampling, compute $\mathcal{E}_\phi$ over current atoms and static sites, backpropagate $\nabla_X \mathcal{E}_\phi$, and correct the score or velocity field.

Fig. 1. ESField 的三阶段流程。注意势能网络不负责发现位点；位点检测是离线冷启动步骤，势能网络只负责评估当前原子与已知位点之间的适配性。

- Far-site negatives: 将真实原子与空间上不相关或类型明显不匹配的位点配对，促使网络学习空间衰减和位点选择。

这种配对策略把三维分子生成中的复杂全局目标拆解为局部可监督任务。它不要求已有实验亲和力和标签，也不要求每个样本都有精确的分解自由能；只需要复合物结构、离线位点地图和可控的负样本构造。

Potential network. 势能网络 E_ϕ 输入当前原子坐标、原子类型和位点描述，输出一个标量势能：

$$E_\phi(\mathbf{x}_i, a_i, s_j) = \text{MLP}_\phi \left[\mathbf{e}_A(a_i), \mathbf{e}_S(\tau_j), \frac{(\mathbf{x}_i - \mathbf{c}_j)/r_j, \|\mathbf{x}_i - \mathbf{c}_j\|_2/r_j, \mathbf{u}_j}{\| \mathbf{x}_i - \mathbf{c}_j \|_2 / r_j} \right]. \quad (3)$$

其中 $\mathbf{e}_A$ 是原子类型嵌入， $\mathbf{e}_S$ 是位点类型嵌入。使用相对位置和归一化距离能够让网络学习“靠近位点中心是否更有利”以及“不同半径位点的作用范围”。我们把低势能解释为吸引，高势能解释为排斥。令 $y_{ij} \in \{0, 1\}$ 表示配对是否为正样本，并定义 $\tilde{y}_{ij} = 2y_{ij} - 1$ 。一个简单的 margin loss 为

$$\mathcal{L}_{\text{pair}} = \mathbb{E}_{(i,j)} [\text{softplus}(\tilde{y}_{ij} E_\phi(\mathbf{x}_i, a_i, s_j) + m)]. \quad (4)$$

当 $y_{ij} = 1$ 时，该损失推动 $E_\phi < -m$ ；当 $y_{ij} = 0$ 时，该损失推动 $E_\phi > m$ 。实际训练中还应加入距离平滑和梯度正则：

$$\mathcal{L} = \mathcal{L}_{\text{pair}} + \lambda_\nabla \mathbb{E} [\|\nabla_{\mathbf{x}} E_\phi(\mathbf{x}, a, s)\|_2^2] + \lambda_{\text{decay}} \mathbb{E} [\mathbb{I}(d > \gamma r) |E_\phi|], \quad (5)$$

避免网络在远离位点处产生过大的虚假力。

Total site energy for a generated ligand. 在生成过程中，原子类型可能不是确定标签，而是模型输出的类型分布 $\pi_i(k)$ 。因此，给定当前坐标 X 和类型分布 Π ，我们定义期望总势能：

$$\mathcal{E}_\phi(X, \Pi; S) = \sum_{i=1}^N \sum_{j=1}^K w_{ij} \sum_{k \in \mathcal{A}} \pi_i(k) E_\phi(\mathbf{x}_i, k, s_j), \quad (6)$$

其中 w_{ij} 是距离权重：

$$w_{ij} = \frac{\exp(-\|\mathbf{x}_i - \mathbf{c}_j\|_2^2 / (2\sigma_j^2))}{\sum_{\ell=1}^K \exp(-\|\mathbf{x}_i - \mathbf{c}_\ell\|_2^2 / (2\sigma_\ell^2)) + \epsilon}. \quad (7)$$

σ_j 可与位点半径 r_j 成比例。该软分配避免最近位点切换时梯度不连续，也允许一个原子同时受到多个邻近物理机会的影响。

对应的位点引导力为

$$\mathbf{F}_{\text{site}}(X, \Pi; S) = -\nabla_X \mathcal{E}_\phi(X, \Pi; S). \quad (8)$$

这一定义保证低势能方向就是引导方向。需要强调的是，原子类型决定受力方向，而不是受力方向反过来决定原子类型。若当前原子以较高概率为疏水碳，则它会主要响应疏水空腔；若当前原子以较高概率为氢键供体或受体，则它会响应相应水位点或极性机会。

Guidance for diffusion models. 对于扩散模型，若未引导模型给出基础分数 $\mathbf{s}_\theta(\mathbf{z}_t, t, P)$ ，而我们希望采样近似来自

$$p_{\text{guided}}(\mathbf{z}_t | P, S) \propto p_\theta(\mathbf{z}_t | P) \exp(-\lambda_t \mathcal{E}_\phi(X_t, \Pi_t; S)), \quad (9)$$

则引导分数可写为

$$\mathbf{s}_{\text{guided}} = \mathbf{s}_\theta - \lambda_t \nabla_{X_t} \mathcal{E}_\phi(X_t, \Pi_t; S). \quad (10)$$

其中 λ_t 是时间相关引导强度。实践上，早期噪声较大时不应过强约束局部位点；中后期结构逐渐成形时可增强引导。因此建议使用 warm-up schedule，例如

$$\lambda_t = \lambda_{\text{max}} \cdot \text{sigmoid}(a(\rho_t - b)), \quad (11)$$

其中 ρ_t 表示从噪声到数据的采样进度。

Guidance for flow matching models. 对于流匹配模型，基础生成过程由 ODE

$$\frac{d\mathbf{z}_t}{dt} = \mathbf{v}_\theta(\mathbf{z}_t, t, P) \quad (12)$$

定义。ESField 将速度场修正为

$$\mathbf{v}_{\text{guided}} = \mathbf{v}_\theta - \eta_t \nabla_{X_t} \mathcal{E}_\phi(X_t, \Pi_t; S), \quad (13)$$

其中 η_t 控制物理位点引导强度。若基础模型同时生成连续坐标和离散原子类型，则坐标更新使用势能梯度，类型更新可通过期望势能影响类型 logits：

$$\ell_i^{\text{guided}}(k) = \ell_i(k) - \mu_t \sum_j w_{ij} E_\phi(\mathbf{x}_i, k, s_j). \quad (14)$$

该式意味着低势能原子类型会在当前位置获得更高 logits，从而让类型选择和坐标移动保持一致。不过第一版实现可以只引导坐标，避免类型引导带来训练和稳定性复杂度。

Practical implementation. 第一版实现建议保持模块边界清晰。位点地图以 pocket-level 文件缓存，每个口袋包含若干行 site records。势能网络可以是 3–5 层 MLP，输入为原子嵌入、位点嵌入、相对坐标、归一化距离和少量位点标量特征。训练时应按 protein split 划分数据，避免同源或同口袋泄漏导致过高估计。

推断时，ESField 只需要三类输入：预训练生成模型当前状态、口袋静态位点地图和势能网络参数。每个采样步计算 $\mathcal{E}_\phi$ ，调用自动微分得到 $\nabla_X \mathcal{E}_\phi$ ，并对梯度做 norm clipping。若某个口袋没有可靠位点，或所有位点离当前原子过远，则引导项自然衰减为零，退化为基础生成模型。

Experimental Design

本节只定义后续实验，不报告结果。

Datasets. 主实验可基于 CrossDocked2020 构建训练和评估集合 (1)。对于每个蛋白-配体复合物，先用标准流程准备蛋白口袋、配体构象和口袋中心，再离线运行位点检测工具。训练势能网络时使用训练集复合物中的原子-位点正负样本；测试时对未见蛋白口袋生成新配体，并评估其亲和力、位点命中和化学合理性。

Baselines. 基础对比应至少包括以下设置：

- Base generator: 不使用 ESField 的预训练口袋条件扩散或流匹配模型。
- Training-time physics baseline: 使用已有训练期物理先验模型，例如 PIDiff 类方法 (2)。
- Hand-crafted site potential: 用人工规则定义原子-位点吸引排斥，而不是学习势能网络。
- Random/incorrect site map: 随机扰动位点坐标或打乱位点类型，用于验证性能提升是否真正来自物理位点。

Metrics. 全局生成质量指标包括 validity、connectivity、QED、SA score、Lipinski 规则、分子量分布、diversity 和 novelty。结合相关指标包括 Vina score、Vina minimization score、pose RMSD（若有参考配体）和药效团相互作用统计。ESField 还需要新增位点级指标：

- Site occupancy: 生成配体是否在高能水或疏水空腔位点附近放置了兼容原子。
- Stable-water violation: 生成配体是否用不兼容原子占据稳定水位点。
- Compatibility energy: $\mathcal{E}_\phi$ 在生成终态上的平均值和分布。
- Gradient alignment: 采样过程中位点引导梯度与基础速度/分数的一致性，用于判断引导是否与基础模型冲突。

MVP validation protocol. 在大规模实验之前，本文首先采用一个最小可行验证（minimum viable prototype, MVP）判断方向是否值得继续投入。MVP 不以证明真实结合自由能降低为目标，而是验证三个更基础的问题：势能网络是否学到了非随机的原子-位点兼容性，推断期引导是否稳定，以及 site-specific metrics 是否优于未引导的 base flow matching 模型。

MVP 的 Go 标准如下。第一，势能网络在 held-out atom-site pairs 上应能区分真实配对和 hard negatives，目标 AUROC 不低于 0.70，或 ranking accuracy 不低于 65%。第二，guided generation 不应出现大规模 NaN 或明显原子塌缩；validity、connectivity 和 PoseBusters pass rate 相比 base generator 的下降不应超过 5 个百分点。第三，至少一个核心位点指标应稳定提升，优先考虑 Correct Atom-Site Matching Rate 或 Site Occupancy Rate，相对提升目标为 10%，或绝对提升不低于 5 个百分点。第四，Vina 或 Vina-min median score 不应明显变差；MVP 阶段不要求 binding proxy 显著提升，但相对 base 的 median 下降最好不超过 0.2 kcal/mol。第五，必须报告 SA score、QED 和分子大小分布，确认改进不是由生成更大或更疏水的分子带来的。

若势能网络接近随机、位点指标没有稳定提升，或引导导致几何质量显著下降，则该 MVP 判为 No-Go。此时应优先检查负样本难度、site map 噪声和 guidance strength，而不是直接扩大实验规模。

Ablation studies. 消融实验应回答四个问题。第一，哪些位点类型贡献最大：只使用高能水、只使用稳定水、只使用疏水空腔，以及三者组合。第二，势能网络是否优于手工规则：比较 MLP 势能、线性兼容矩阵和固定势阱函数。第三，负样本构造是否关键：比较 type-swapped negatives、decoy-pose negatives 和 far-site negatives。第四，引导强度和时间调度是否稳定：扫描 $\lambda_{\max}$ 、warm-up 位置和 gradient clipping 阈值，观察亲和力提升与结构崩坏之间的权衡。

Case studies. 顶会论文需要强可解释案例。建议选择三类代表性口袋：含有可置换高能水的口袋、含有稳定水网络的口袋、含有明显疏水子腔的口袋。每个案例展示基础模型和 ESField 生成分子的差异，包括位点地图、生成轨迹中关键原子的移动方向、终态相互作用和 docking/minimization 后的构象变化。若实验支持，案例应证明 ESField 不是简单把分子整体拉向口袋中心，而是把特定类型原子拉向特定物理机会位点。

Discussion

ESField 的最大优势是可插拔和可解释。它不要求重新训练主生成模型，也不把复杂物理模拟放进每个采样步，而是将昂贵或离散的物理分析前置为离线位点地图。生成时，势能网络提供的是局部、可微、可追踪的引导力。对于早期 idea 验证，这种设计比端到端重训更容易做出清晰消融，也更容易定位失败原因。

该方法也有明显风险。第一，位点检测质量会成为上游瓶颈。如果 WATsite 或 fpocket 给出的位点不稳定，ESField 会把错误机会强化到生成过程中。第二，静态位点地图忽略蛋白构象变化。对于诱导契合或 cryptic pocket 场景，固定口袋可能不足以描述真实机会。第三，

局部原子-位点势能可能无法完全代表全分子结合自由能。例如，一个原子命中高能水位点并不保证整分子构象、键长键角、合成可及性和 ADMET 性质合理。第四，引导强度过大可能破坏基础生成模型学到的分子先验，导致局部位点满足但整体化学质量下降。

这些风险决定了后续实验不能只看 Vina 分数。必须同时报告化学有效性、合成可及性、位点级命中率和失败案例。若出现亲和力提升但化学合理性下降，说明需要更弱的引导、更晚的引导调度，或将 ESField 与合成可及性引导联合使用。若位点命中率提升但 Vina 不提升，说明势能网络学到了局部兼容性，但与全局结合评分仍有差距，需要引入更强的负样本或更丰富的位点上下文。

Conclusion

本文提出 ESField，一种面向口袋条件三维分子生成的推断期能量位点引导框架。ESField 将高能水、稳定水和疏水空腔等物理机会抽象为静态位点地图，并训练原子-位点势能网络来产生可微引导力。该方法的关键不是重新发定位点检测，也不是替代现有生成模型，而是把成熟物理分析与现代扩散/流匹配生成模型连接起来：位点检测负责告诉模型“哪里有机会”，势能网络负责告诉模型“什么原子适合这个机会”，推断期梯度负责把生成轨迹推向更合理的构型。

当前稿件仍处于实验前设计阶段。下一步应优先完成位点预处理脚本、原子-位点样本构造、势能网络训练和一个最小可运行的推断期引导 demo。只有当这些模块闭环后，才能进一步判断 ESField 是否能够在不牺牲化学合理性的前提下稳定提升结合亲和力和位点利用率。

ACKNOWLEDGEMENTS

This is an internal Chinese draft for method planning. Experimental results are intentionally omitted.

Bibliography

1. Paul G. Francoeur, Tomohide Masuda, Jocelyn Sunseri, Andrew Jia, Richard B. Iovanisci, Ian Snyder, and David R. Koes. Three-dimensional convolutional neural networks and a cross-docked data set for structure-based drug design. *Journal of Chemical Information and Modeling*, 60(9):4200–4215, 2020. doi: 10.1021/acs.jcim.0c00411.
2. Seungyeon Choi, Sangmin Seo, Byung Ju Kim, Chihyun Park, and Sanghyun Park. PIDiff: Physics informed diffusion model for protein pocket-specific 3d molecular generation. *Computers in Biology and Medicine*, 180:108865, 2024. doi: 10.1016/j.combiomed.2024.108865.
3. Xiangxin Zhou, Yi Xiao, Haowei Lin, Xinheng He, Jiaqi Guan, Yang Wang, Qiang Liu, Feng Zhou, Liang Wang, and Jianzhu Ma. Integrating protein dynamics into structure-based drug design via full-atom stochastic flows. *arXiv preprint arXiv:2503.03989*, 2025. doi: 10.48550/arXiv.2503.03989.
4. Xiwei Cheng, Xiangxin Zhou, Yuwei Yang, Yu Bao, and Quanquan Gu. Decomposed direct preference optimization for structure-based drug design. *arXiv preprint arXiv:2407.13981*, 2026. doi: 10.48550/arXiv.2407.13981.
5. Yunfan Liu, Lirong Wu, Zhifeng Gao, Yufei Huang, Cheng Tan, Haitao Lin, Zicheng Liu, Changxi Chi, Chang Yu, and Stan Z. Li. SYNC: Measuring and advancing synthesizability in structure-based drug design. *Manuscript*, 2026.
6. Balazs Zoltan Zsido and Csaba Hetenyi. Water in drug design: Pitfalls and good practices. *Expert Opinion on Drug Discovery*, 20(6):745–764, 2025. doi: 10.1080/17460441.2025.2497912.
7. Diya Zhang, Qiaozhen Meng, and Fei Guo. Incorporating water molecules into highly accurate binding affinity prediction for proteins and ligands. *International Journal of Molecular Sciences*, 25(23):12676, 2024. doi: 10.3390/ijms252312676.
8. Zhiqi Xie, Peng Zhang, Zipeng Fan, Qingpeng Zhang, and Qianxi Lin. EM-PLA: Environment-aware heterogeneous graph-based multi-modal protein-ligand binding affinity prediction. *Bioinformatics*, 41(7):btaf298, 2025. doi: 10.1093/bioinformatics/btaf298.
9. Bingjie Hu and Markus A. Lill. WATsite: Hydration site prediction program with PyMOL interface. *Journal of Computational Chemistry*, 35(16):1255–1260, 2014. doi: 10.1002/jcc.23616.
10. Andreas Zamanos, George Ioannakis, and Ioannis Z. Emiris. HydraProt: A new deep learning tool for fast and accurate prediction of water molecule positions for protein structures. *Journal of Chemical Information and Modeling*, 64(7):2594–2611, 2024. doi: 10.1021/acs.jcim.3c01559.
11. Xiaohan Kuang, Zhaoqian Su, Yunchao Liu, Xiaobo Lin, Jesse Spencer-Smith, Tyler Derr, Yinghao Wu, and Jens Meiler. SuperWater: Predicting water molecule positions on protein structures by generative AI. *bioRxiv*, 2024. doi: 10.1101/2024.11.18.624208.
12. Erik B. Nordquist, Mingtian Zhao, Anmol Kumar, and Alexander D. MacKerell. Combined physics- and machine-learning-based method to identify druggable binding sites using SILCS-hotspots. *Journal of Chemical Information and Modeling*, 64(19):7743–7757, 2024. doi: 10.1021/acs.jcim.4c01189.
13. Cheng Lu, Huayu Chen, Jianfei Chen, Hang Su, Chongxuan Li, and Jun Zhu. Contrastive energy prediction for exact energy-guided diffusion sampling in offline reinforcement learning. *Proceedings of the 40th International Conference on Machine Learning*, 2023.
14. Vincent Le Guilloux, Peter Schmidtke, and Pierre Tuffery. Fpocket: An open source platform for ligand pocket detection. *BMC Bioinformatics*, 10:168, 2009. doi: 10.1186/1471-2105-10-168.
15. Alfonso Trezza, Anna Visibelli, Bianca Roncaglia, Roberta Barletta, Stefania Iannielli, Linta Mahboob, Ottavia Spiga, and Annalisa Santucci. Unveiling dynamic hotspots in protein-ligand binding: Accelerating target and drug discovery approaches. *International Journal of Molecular Sciences*, 26(9):3971, 2025. doi: 10.3390/ijms26093971.
16. Ying Xia, Xiaoyong Pan, and Hong-Bin Shen. A comprehensive survey on protein-ligand binding site prediction. *Current Opinion in Structural Biology*, 86:102793, 2024. doi: 10.1016/j.sbi.2024.102793.
17. Wenyin Zhou, Christopher Iliffe Sprague, Vsevolod Viliuga, Matteo Tadiello, Arne Elofsson, and Hossein Azizpour. Energy-based flow matching for generating 3d molecular structure. *arXiv preprint arXiv:2508.18949*, 2025. doi: 10.48550/arXiv.2508.18949.